

Destek Vektör Makineleri

Dr. Caner Erden cerden@sakarya.edu.tr

Sakarya Üniversitesi, Endüstri Mühendisliği Bölümü




SAKARYA
ÜNİVERSİTESİ


Destek Vektör Makineleri(DVM)

- Bu yöntem sınıflandırmayı bir doğrusal ya da doğrusal olmayan bir fonksiyon yardımıyla yerine getirir.
- Veriyi birbirinden ayırmak için en uygun fonksiyonun tahmin edilmesi esasına dayanır.


- Verileri birbirinden ayıran bir çizgi bulalım




- Muhtemel Bir Çözüm



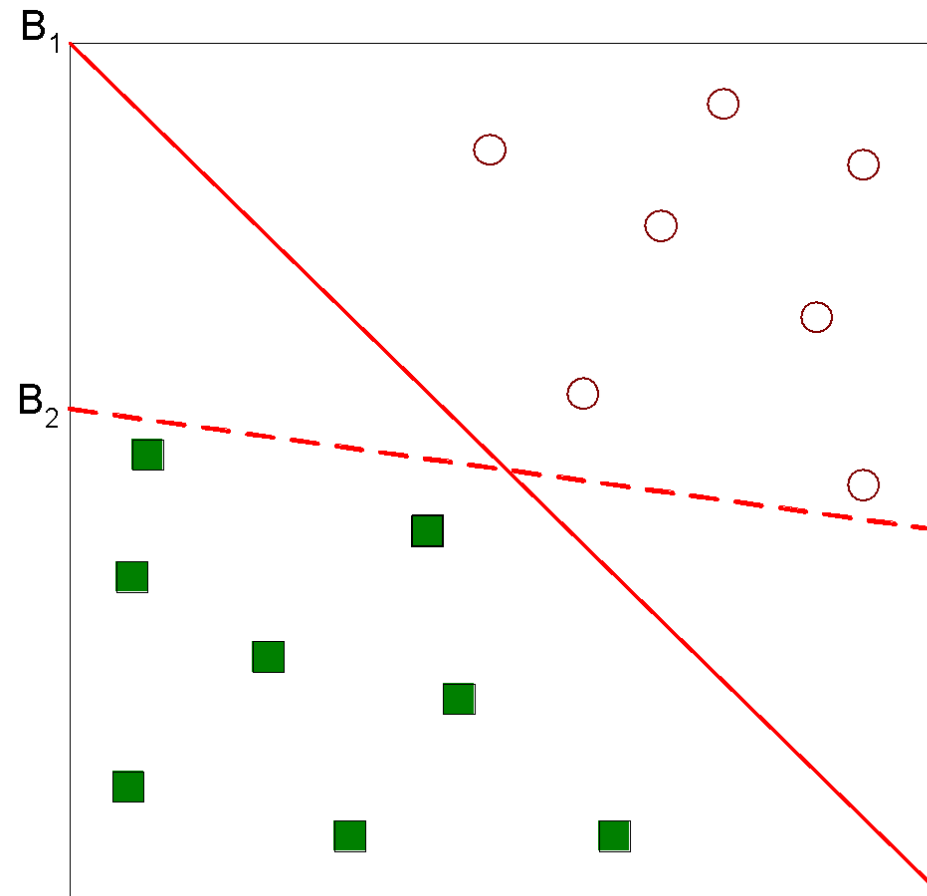
- Diğer Muhtemel Bir Çözüm




- Birçok muhtemel çözüm




B1 ya da B2'den hangisi daha iyi?
Daha iyiyi nasıl tanımlıyoruz.



Buradaki aralığı maksimize eden çubuğu bulalım => B1
B2'den iyidir.





$$f(\vec{x}) = \begin{cases} 1 & \text{if } \vec{w} \bullet \vec{x} + b \geq 1 \\ -1 & \text{if } \vec{w} \bullet \vec{x} + b \leq -1 \end{cases}$$

$$\text{Margin} = \frac{2}{\|\vec{w}\|}$$

Hiper düzlemin üst tarafında kalan noktalar :

$$W^T X + b > 0, \quad y_1 = +1$$

Hiper düzlemin alt tarafında kalan noktalar ise

$$W^T X + b < 0, \quad y_2 = -1 \text{ eşitsizliğine uyar.}$$

Eşitsizlikleri birleştirilerek tek bir eşitsizliğe dönüşür:

$$y_i (W^T X + b) - 1 \geq 0$$

- Bir destek vektör ile $H_0 : W^T X + b = 0$ ile gösterilen hiper düzlemi arasındaki uzaklık, P hiper düzlemi üzerindeki bir nokta olmak üzere:

$$d = \frac{|WX'_P \pm b|}{\|w\|} = \frac{|w_1 x_{1P} + w_2 x_{2P} + \dots + w_n x_{nP} + b|}{\sqrt{w_1^2 + w_2^2 + \dots + w_n^2}}$$

- O halde X_1 destek vektörü ile H_2 hiper düzlemi arasındaki uzaklık:

$$d = \frac{|W^T X_1 + b|}{\|w\|} = \frac{1}{\|w\|} \quad \text{biçiminde hesaplanır.}$$

Bu durumda $m = 2d = \frac{2}{\|w\|}$ olur.

Lineer DVM

- Linear Model:
$$f(\mathbf{x}) = \begin{cases} 1 & \text{if } \mathbf{w} \bullet \mathbf{x} + b \geq 1 \\ -1 & \text{if } \mathbf{w} \bullet \mathbf{x} + b \leq -1 \end{cases}$$
- Modelin öğrenmesi \mathbf{w} and b iki değerin belirlenmesi ile gerçekleşir
- Bu değerler \mathbf{w} and b nasıl belirlenecek?

Amaç Maksimizasyon: $\text{Margin} = \frac{2}{\|\mathbf{w}\|}$


Burada minizasyonu yapılacak: $L(\mathbf{w}) = \frac{\|\mathbf{w}\|^2}{2}$
Kısıtlar şu şekildedir:

$$\text{ya da } y_i = \begin{cases} 1 & \text{if } \mathbf{w} \bullet \mathbf{x}_i + b \geq 1 \\ -1 & \text{if } \mathbf{w} \bullet \mathbf{x}_i + b \leq -1 \end{cases}$$

$$y_i(\mathbf{w} \bullet \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, N$$

Bu problem kısıtlı optimizasyon problemidir.

Örnek bir çalışma




Destek Vektörleri

x1	x2	y	λ
0.3858	0.4687	1	65.5261
0.4871	0.611	-1	65.5261
0.9218	0.4103	-1	0
0.7382	0.8936	-1	0
0.1763	0.0579	1	0
0.4057	0.3529	1	0
0.9355	0.8132	-1	0
0.2146	0.0099	1	0

DVM

- Peki ya problem tam doğrusal olarak ayrılmazsa?



- O zaman slack değişkenler devreye girer
 - Yani problem şuna döner

◆ Minimizasyon:


$$L(w) = \frac{\|w\|^2}{2} + C \left(\sum_{i=1}^N \xi_i^k \right)$$

◆ Kısıtlar:

$$y_i = \begin{cases} 1 & \text{if } w \bullet x_i + b \geq 1 - \xi_i \\ -1 & \text{if } w \bullet x_i + b \leq -1 + \xi_i \end{cases}$$

Lineer Olmayan DVM


- Peki ya sınırlar lineer değilse?



$$y(x_1, x_2) = \begin{cases} 1 & \text{if } \sqrt{(x_1 - 0.5)^2 + (x_2 - 0.5)^2} > 0.2 \\ -1 & \text{otherwise} \end{cases}$$

Lineer Olmayan SVM

- O zaman veriler daha büyük bir veri uzayına taşınır.



$$x_1^2 - x_1 + x_2^2 - x_2 = -0.46.$$

$$\Phi : (x_1, x_2) \longrightarrow (x_1^2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2, 1).$$

$$w_4x_1^2 + w_3x_2^2 + w_2\sqrt{2}x_1 + w_1\sqrt{2}x_2 + w_0 = 0.$$

Sınırlar:

$$\underline{w} \bullet \Phi(\underline{x}) + b = 0$$

Lineer Olmayan DVM

- Optimizasyon Problemi:

$$\min_w \frac{\|\mathbf{w}\|^2}{2}$$

subject to $y_i(\mathbf{w} \cdot \Phi(\mathbf{x}_i) + b) \geq 1, \forall \{(\mathbf{x}_i, y_i)\}$

$$L_D = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j y_i y_j \Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j) \quad \mathbf{w} = \sum_i \lambda_i y_i \Phi(\mathbf{x}_i)$$
$$\lambda_i \{y_i (\sum_j \lambda_j y_j \Phi(\mathbf{x}_j) \cdot \Phi(\mathbf{x}_i) + b) - 1\} = 0,$$

$$f(\mathbf{z}) = \text{sign}(\mathbf{w} \cdot \Phi(\mathbf{z}) + b) = \text{sign}(\sum_{i=1}^n \lambda_i y_i \Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{z}) + b).$$

Kaynaklar

- Akküçük, Ulaş. “Veri madenciliği: kümeleme ve sınıflama algoritmaları”. *İstanbul: Yalın Yayıncılık* 18 (2011).
- Han, Jiawei, Jian Pei, ve Micheline Kamber. *Data mining: concepts and techniques*. Elsevier, 2011.
- Kantardzic, Mehmed. *Data mining: concepts, models, methods, and algorithms*. John Wiley & Sons, 2011.
- Sumathi, Sai, ve S. N. Sivanandam. *Introduction to data mining and its applications*. C. 29. Springer, 2006.
- Tan, Pang-Ning, Michael Steinbach, ve Vipin Kumar. *Introduction to data mining*. Pearson Education India, 2016.
- Towards Data Science. “Towards Data Science”. Erişim 29 Mart 2020. <https://towardsdatascience.com/>.
- VanderPlas, Jake. *Python Data Science Handbook*. OReilly Media. Inc, 2017.